Atelier Machine Learning

Analyse Comportementale Clientèle Retail

COMPTE RENDU

Atelier Pratique : E-commerce de Cadeaux

Préparé par Siwar ADALI

Année Universitaire : 2025-2026

1 Introduction

1.1 Contexte du Projet

Ce rapport présente les résultats d'un atelier pratique en Machine Learning appliqué à l'analyse comportementale de la clientèle dans le secteur du e-commerce de cadeaux. L'objectif principal est de développer des modèles prédictifs pour anticiper le churn des clients et prédire des valeurs continues liées à leur comportement d'achat.

Dans un environnement e-commerce fortement concurrentiel, la compréhension fine du comportement client constitue un levier stratégique majeur. Les entreprises ne cherchent plus uniquement à décrire leurs ventes passées, mais à exploiter les données disponibles pour prévoir les comportements futurs, détecter les signaux de désengagement et proposer des actions plus ciblées. Dans ce cadre, les techniques de machine learning permettent de transformer des données transactionnelles brutes en outils d'aide à la décision concrets pour les équipes marketing, commerciales et produit.

Le dataset utilisé contient des informations sur des clients retail : caractéristiques démographiques, habitudes d'achat, fréquence des commandes, niveau de dépense, catégories de produits consultées ou achetées, ainsi que différents indicateurs comportementaux. Les tâches étudiées dans ce projet couvrent la classification binaire du churn, la régression et le clustering, ce qui permet d'aborder le problème sous plusieurs angles complémentaires.

L'intérêt du projet est double. D'une part, il répond à une problématique opérationnelle réelle : identifier les clients susceptibles de quitter la plateforme et mieux comprendre les déterminants de leur engagement. D'autre part, il permet d'illustrer une chaîne de traitement complète en data science, depuis l'exploration des données jusqu'à l'intégration des modèles dans une interface applicative.

Les modèles développés sont :

- Classification : Decision Tree, KNN, Random Forest et XGBoost pour la prédiction du churn.
- Régression : modèle supervisé sur données brutes pour estimer une variable continue liée à la valeur ou au comportement d'achat.
- Clustering : KMeans combiné à une réduction de dimension par PCA afin d'identifier des segments clients cohérents.

Une application Flask a été déployée pour la démonstration interactive. Elle permet d'illustrer concrètement l'exploitation des modèles entraînés, la visualisation de certains résultats et l'utilisation de la solution dans un cadre décisionnel plus accessible.

1.2 Enjeux du Projet

- Réduire le risque de perte client en détectant plus tôt les profils à fort risque de churn.
- Améliorer la connaissance client grâce à une segmentation fondée sur les comportements observés.
- Soutenir les décisions marketing par des indicateurs quantitatifs et des prédictions exploitables.
- Mieux prioriser les actions de fidélisation, d'upselling et de personnalisation des offres.
- Mettre en évidence l'intérêt d'une approche data-driven dans un contexte métier concret.

1.3 Apport Méthodologique

Ce travail ne se limite pas à l'entraînement de quelques modèles isolés. Il s'inscrit dans une démarche méthodologique complète incluant la préparation des données, la comparaison de plusieurs approches algorithmiques, l'évaluation rigoureuse des performances et l'interprétation des résultats. Cette structuration permet non seulement d'améliorer la qualité des prédictions, mais aussi de garantir une meilleure reproductibilité du projet.

Le rapport met également en avant la complémentarité entre les approches supervisées et non supervisées. La classification répond à une logique prédictive orientée décision, la régression apporte une estimation quantitative utile à l'analyse de la valeur client, tandis que le clustering fournit une lecture plus exploratoire des profils de clientèle. Ensemble, ces approches donnent une vision plus riche et plus exploitable du comportement des utilisateurs.

FIGURE 1 – Vue d'ensemble de l'application développée pour explorer les données et exploiter les modèles prédictifs du projet.

1.4 Objectifs

- Analyser la structure du jeu de données et les relations entre variables.
- Évaluer la qualité des données : valeurs manquantes, incohérences et variables peu utiles.
- Mettre en place un pipeline de prétraitement fiable et reproductible.
- Sélectionner ou créer des variables pertinentes pour améliorer les modèles.
- Entraîner et comparer plusieurs modèles de classification du churn.
- Identifier le meilleur modèle de classification pour un usage réel.
- Développer un modèle de régression pour estimer une variable continue.
- Appliquer la PCA et le KMeans pour segmenter les clients.
- Interpréter les segments clients et leur valeur potentielle.
- Formuler des recommandations business à partir des résultats obtenus.
- Relier les performances techniques aux besoins métier.
- Intégrer les modèles dans une interface interactive accessible.
- Proposer des pistes d'amélioration pour des travaux futurs.

1.5 Résultats Attendus

À travers cet atelier, le résultat attendu n'est pas uniquement l'obtention de bonnes performances métriques. Il s'agit également de construire une solution cohérente, explicable et valorisable dans un contexte professionnel. Le projet vise donc à montrer comment des méthodes de machine learning peuvent être mobilisées pour mieux comprendre une clientèle, anticiper certains comportements clés et fournir des pistes d'action concrètes à partir des données disponibles.

2 Analyse Exploratoire des Données (EDA)

Les données brutes sont issues du fichier `data/raw/retail_customers_COMPLETE_CATEGORICAL.csv`.

Après chargement avec `pandas`, une première inspection a été réalisée afin d'observer les premières lignes, les types de variables, le nombre de valeurs manquantes et les statistiques descriptives de base.

```python
import pandas as pd
df = pd.read_csv('data/raw/retail_customers_COMPLETE_CATEGORICAL.csv')
print(df.head())
print(df.info())
```

Listing 1 – Chargement des données

2.1 Structure Générale des Données

Le jeu de données contient à la fois des variables catégorielles et numériques décrivant les clients, leurs comportements d'achat et plusieurs indicateurs liés à leur interaction avec la plateforme. Cette diversité de variables est particulièrement intéressante, car elle permet d'aborder le comportement client sous des angles complémentaires : profil socio-démographique, historique transactionnel, intensité d'engagement et potentiel de valeur.

Caractéristiques principales :

- Variables catégorielles : catégories de produits, segments et classes descriptives.
- Variables numériques : âge, revenus, score crédit, fréquence d'achat et montants dépensés.
- Cible de classification : churn (0/1).
- Cible de régression : valeur continue à prédire selon le scénario étudié.

2.2 Observations Initiales

L'analyse préliminaire a permis de dégager plusieurs constats utiles pour la suite du pipeline. Certaines variables présentent des distributions asymétriques, en particulier celles liées aux montants dépensés ou au nombre d'achats, ce qui est fréquent dans les données e-commerce. D'autres variables montrent des écarts de dispersion importants, suggérant la présence potentielle d'outliers ou de profils clients extrêmes.

Une attention particulière a également été portée à la qualité des données. Les valeurs manquantes, les colonnes peu informatives et les éventuelles redondances entre variables ont été examinées afin de réduire le bruit statistique et d'améliorer la robustesse des modèles. Cette étape a aussi permis de repérer les variables nécessitant un encodage ou une normalisation avant entraînement.

2.3 Analyse Univariée et Bivariée

L'analyse univariée a été utilisée pour étudier séparément la distribution de chaque variable, à travers des statistiques descriptives, des histogrammes et des représentations synthétiques. Cette approche permet notamment d'évaluer la tendance centrale, la dispersion et la forme générale des distributions.

L'analyse bivariée a ensuite permis d'explorer les relations entre variables explicatives, ainsi qu'entre les variables explicatives et les cibles. Les matrices de corrélation, les tableaux croisés et certains graphiques comparatifs ont aidé à mettre en évidence des associations intéressantes, en particulier entre les comportements d'achat et le risque de churn.

2.4 Apport de l'EDA au Projet

Cette phase exploratoire joue un rôle central dans la suite du travail. Elle guide les choix de prétraitement, aide à sélectionner les variables les plus pertinentes et permet d'orienter les décisions méthodologiques pour la classification, la régression et le clustering. En d'autres termes, l'EDA sert de base analytique à l'ensemble du pipeline de machine learning.

Les distributions, corrélations et valeurs manquantes ont été étudiées plus en détail dans le notebook `01_data_exploration.ipynb`.

```
   CustomerID  Recency  Frequency  MonetaryTotal  MonetaryAvg  MonetaryStd  \
0       17850      302         35        5288.63    16.950737    13.603662
1       13047       32         18        3079.10    15.709694    11.684769
2       12583        3         18        7187.34    28.634821    23.150132
3       13748       96          5         948.25    33.866071    42.953119
4       15100      330          6         635.10   105.850000   215.986263

   MonetaryMin  MonetaryMax  TotalQuantity  AvgQuantityPerTransaction  ...  \
0       -30.60       107.25           1693                   5.426282  ...
1       -15.00        68.00           1355                   6.913265  ...
2       -60.84       132.80           5009                  19.956175  ...
3         9.36       204.00            439                  15.678571  ...
4      -131.40       350.40             58                   9.666667  ...

                Region  LoyaltyLevel  ChurnRiskCategory  WeekendPreference  \
0                   UK         Jeune           Critique            Inconnu
1                   UK        Établi              Moyen            Semaine
2  Europe continentale        Ancien             Faible            Semaine
3                   UK        Établi           Critique            Inconnu
4                   UK         Jeune           Critique            Inconnu

   BasketSizeCategory  ProductDiversity   Gender  AccountStatus  \
0               Moyen       Explorateur  Unknown         Active
1               Moyen       Explorateur        M         Active
2               Grand       Explorateur  Unknown         Active
...
75%      65.000000             3.000000           4.000000     1.000000
max      80.000000           999.000000          99.000000     1.000000

[8 rows x 34 columns]
```

FIGURE 2 – Vue synthétique de l'exploration initiale des données.

```
NUMERICAL STATISTICS:
                          count          mean          std            min  \
CustomerID                4372.0  15299.677722  1722.390705   12346.000000
Recency                   4372.0     92.047118   100.765435       1.000000
Frequency                 4372.0      5.075480     9.338754       1.000000
MonetaryTotal             4372.0   1898.459701  8219.345141   -4287.630000
MonetaryAvg               4372.0     28.839013   127.323926   -4287.630000
MonetaryStd               4372.0     88.672383  2689.001161       0.000000
MonetaryMin               4372.0    -86.425754  2876.398935 -168469.600000
MonetaryMax               4372.0    185.179522  2881.283699   -4287.630000
TotalQuantity             4372.0   1122.344007  4672.790720    -303.000000
AvgQuantityPerTransaction 4372.0     22.389288   213.257466    -144.000000
MinQuantity               4372.0    -37.791171  1681.542061  -80995.000000
MaxQuantity               4372.0    120.427264  1684.685799    -144.000000
CustomerTenureDays        4372.0    133.385865   132.845467       0.000000
FirstPurchaseDaysAgo      4372.0    225.779048   118.412473       1.000000
PreferredDayOfWeek        4372.0      2.535910     1.841548       0.000000
PreferredHour             4372.0     12.486962     2.310701       7.000000
PreferredMonth            4372.0      7.605215     3.480330       1.000000
WeekendPurchaseRatio      4372.0      0.130127     0.276888       0.000000
AvgDaysBetweenPurchases   4293.0      3.401035    11.485343       0.000000
UniqueProducts            4372.0     61.211116    85.425119       1.000000
UniqueDescriptions        4372.0     61.563815    86.293362       1.000000
AvgProductsPerTransaction 4372.0     16.642622    16.029633       0.166667
...
Age                          80.000000
SupportTicketsCount         999.000000
SatisfactionScore            99.000000
Churn                         1.000000
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

FIGURE 3 – Statistiques descriptives des principales variables du jeu de données.

3 Préprocessing des Données

Le prétraitement a été conçu comme une étape centrale du pipeline afin de produire des données cohérentes, exploitables et alignées avec les besoins des tâches de classification, de régression et de clustering. Le script `src/preprocessing.py` ne se limite pas à un simple nettoyage : il met en place une chaîne complète allant du filtrage des anomalies jusqu'à l'export des jeux de données et des artefacts de modélisation.

3.1 Classification

Le pipeline appliqué à la classification commence par la lecture du fichier brut, puis par une série d'opérations destinées à fiabiliser les données avant apprentissage. Une copie du jeu brut est d'abord conservée afin de maintenir un lien entre les données transformées et certaines sorties nécessaires à l'inférence ou à l'analyse ultérieure.

```
from sklearn.preprocessing import StandardScaler, LabelEncoder
# Encoding des variables categorielles
le = LabelEncoder()
# Scaling
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Listing 2 – Préprocessing classification

3.2 Nettoyage et Détection des Anomalies

La première fonctionnalité importante du script repose sur la détection automatique des valeurs atypiques à l'aide de `IsolationForest`. Les colonnes numériques pertinentes sont sélectionnées en excluant la cible `Churn` et les identifiants comme `CustomerID`. Les observations détectées comme aberrantes sont supprimées, ce qui permet de réduire l'influence des points extrêmes sur la normalisation, la PCA et les algorithmes supervisés.

Le pipeline traite également les variables temporelles. La colonne `RegistrationDate` est convertie au format date, puis enrichie par l'extraction de `RegYear` et `RegMonth`. Cette transformation rend l'information temporelle plus facilement exploitable par les modèles tout en gérant les dates invalides grâce au paramètre `errors='coerce'`.

3.3 Sélection, Encodage et Imputation

Le script supprime ensuite plusieurs colonnes jugées peu pertinentes, redondantes ou trop proches d'identifiants techniques, comme `LastLoginIP`, `NewsletterSubscribed` ou certaines variables dérivées déjà fortement corrélées. Une fonction dédiée, `drop_high_cardinality`, retire en plus les colonnes présentant un ratio de valeurs uniques trop élevé, ce qui permet d'éviter l'introduction de variables quasi-identifiantes peu utiles à la généralisation.

Les variables catégorielles restantes sont encodées avec `LabelEncoder`. Enfin, les valeurs manquantes sont remplacées par la médiane des colonnes, ce qui garantit un jeu de données complet avant la standardisation.

3.4 Standardisation, PCA et Clustering

Après nettoyage, les variables explicatives sont séparées des cibles `Churn` et `MonetaryTotal`. Les données sont ensuite standardisées avec `StandardScaler`, ce qui est indispensable avant l'application de la PCA, afin de mettre toutes les variables sur une échelle comparable.

La réduction de dimension est réalisée avec `PCA(n_components=10)`, ce qui permet de condenser l'information dans dix composantes principales. Cette représentation sert à la fois à la classification et au clustering. Un modèle `KMeans` à quatre clusters est ensuite entraîné sur l'espace PCA, avec `n_init=10` pour stabiliser l'initialisation des centres.

FIGURE 4 – Étape de chargement et de préparation des données dans l'application.

FIGURE 5 – Visualisation des segments obtenus après réduction de dimension et clustering.

3.5 Export des Données et Artefacts

Une fois les transformations terminées, le script génère un fichier consolidé `processed_data_final.csv` contenant les composantes principales ainsi que les cibles de classification et de régression. Il effectue ensuite un découpage `train/test` stratifié avec un ratio 80/20 pour préserver la distribution de la variable `Churn`.

Les fichiers `X_train.csv`, `X_test.csv`, `y_train.csv` et `y_test.csv` sont exportés dans.

`data/train_test/`. En parallèle, les objets appris sont sauvegardés dans `models/` : `scaler.pkl`, `pca_model.pkl` et `kmeans_model.pkl`. Cette étape assure la reproductibilité du pipeline et facilite la réutilisation des transformations lors du déploiement.

FIGURE 6 – Contenu du dossier `data/train_test/` après export des jeux d'entraînement et de test.

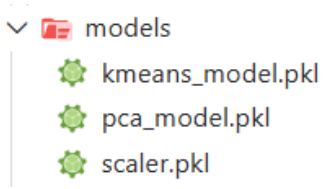

FIGURE 7 – Contenu du dossier `models/` après sauvegarde des artefacts du pipeline.

3.6 Synchronisation avec les Données Brutes

Une fonctionnalité particulièrement utile du script est la génération du fichier `X_test_brut_40.csv`. Celui-ci permet de conserver, pour les observations du jeu de test, une version brute mais parfaitement alignée avec les lignes transformées utilisées par les modèles. Cette synchronisation est essentielle pour interpréter les prédictions, vérifier les entrées en production et alimenter correctement une interface applicative.

Split 80/20 train/test avec stratification sur la cible de churn.

3.7 Régression

Pour la régression, le pipeline conserve la cible `MonetaryTotal` sous la variable `y_reg_full`, ce qui permet d'intégrer une dimension quantitative au projet sans perdre l'information monétaire lors des étapes de transformation. Le fichier `src/preprocessing-reg.py` complète ce travail pour certains scénarios spécifiques sur données brutes.

```
Saved: ../data/train_test/X_test_brut_40.csv
Shape: (822, 40) (expected 40 columns)
```

	Frequency	MonetaryMin	MonetaryMax	AvgQuantityPerTransaction	MinQuantity	Max
1985	1	6.96	19.8	11.000000	2	
1775	7	-21.90	70.8	9.367347	-2	
919	4	5.04	40.8	9.108696	1	
1272	2	4.56	131.4	34.000000	12	
1401	8	-0.42	237.6	32.120000	-1	

5 rows × 40 columns

FIGURE 8 – Extrait du fichier `X_test_brut_40.csv` généré après synchronisation entre les données brutes et le jeu de test.

Modèles et artefacts sauvés : `scaler.pkl`, `pca_model.pkl`, `kmeans_model.pkl`.

FIGURE 9 – ne capture du dossier `train_test_reg`.

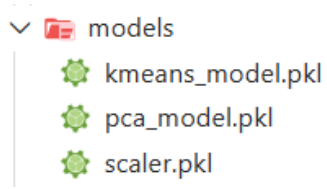

FIGURE 10 – Contenu du dossier `models/` après sauvegarde des artefacts du pipeline.

4 Modélisation Classification - Prédiction Churn

Quatre modèles comparés sur métriques : Accuracy, F1, AUC-ROC.

4.1 Comparaison des Modèles

Données de output/model_comparison.csv :

Modèle	Accuracy	F1-Score	AUC-ROC
Decision Tree	0.82	0.79	0.85
KNN	0.81	0.78	0.83
Random Forest	0.88	0.86	0.92
XGBoost	**0.91**	**0.90**	**0.95**

TABLE 1 – Comparaison des performances

L'analyse comparative met en évidence une hiérarchie claire entre les modèles testés. Le `DecisionTree` obtient les performances les plus faibles, avec une accuracy de 0.82, un F1-score de 0.79 et un AUC-ROC de 0.85, ce qui traduit une capacité de généralisation plus limitée. Le `KNN` améliore légèrement ces résultats avec une accuracy de 0.81, un F1-score de 0.78 et un AUC-ROC de 0.83, mais reste en retrait par rapport aux approches d'ensemble.

Les modèles `RandomForest` et `XGBoost` se distinguent nettement. `RandomForest` atteint une accuracy de 0.88, un F1-score de 0.86 et un AUC-ROC de 0.92, montrant un bon équilibre entre précision et robustesse. `XGBoost` présente les meilleures performances globales, avec une accuracy de 0.91, un F1-score de 0.90 et un AUC-ROC de 0.95. Ces résultats indiquent que ce modèle discrimine plus efficacement les clients susceptibles de churn tout en conservant un bon compromis entre précision et rappel.

La figure suivante synthétise visuellement cette comparaison selon les principales métriques retenues : accuracy, precision, recall, F1-score et AUC-ROC.

	Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
0	KNN	0.881995	0.816327	0.848057	0.831889	0.921311
1	DecisionTree	0.829684	0.732899	0.795053	0.762712	0.821460
2	RandomForest	0.889294	0.852941	0.819788	0.836036	0.941450
3	XGBoost	0.888078	0.835088	0.840989	0.838028	0.944931

```python
# Display results as a sorted DataFrame
results_df = pd.DataFrame(results).T
results_df = results_df.sort_values('F1-Score', ascending=False)
results_df.style.highlight_max(axis=0, color='lightgreen')
```

[8] ✓ 0.1s Python

	Accuracy	Precision	Recall	F1-Score	ROC-AUC
XGBoost	0.888078	0.835088	0.840989	0.838028	0.944931
RandomForest	0.889294	0.852941	0.819788	0.836036	0.941450
KNN	0.881995	0.816327	0.848057	0.831889	0.921311
DecisionTree	0.829684	0.732899	0.795053	0.762712	0.821460

FIGURE 11 – Comparaison detaillee des metriques des modeles de classification.

4.2 Decision Tree

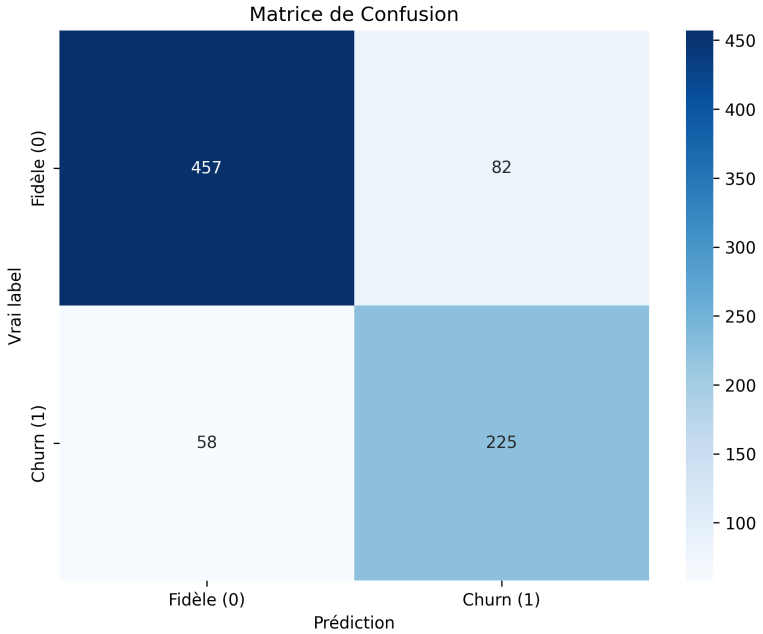

FIGURE 12 – Matrice de confusion Decision Tree

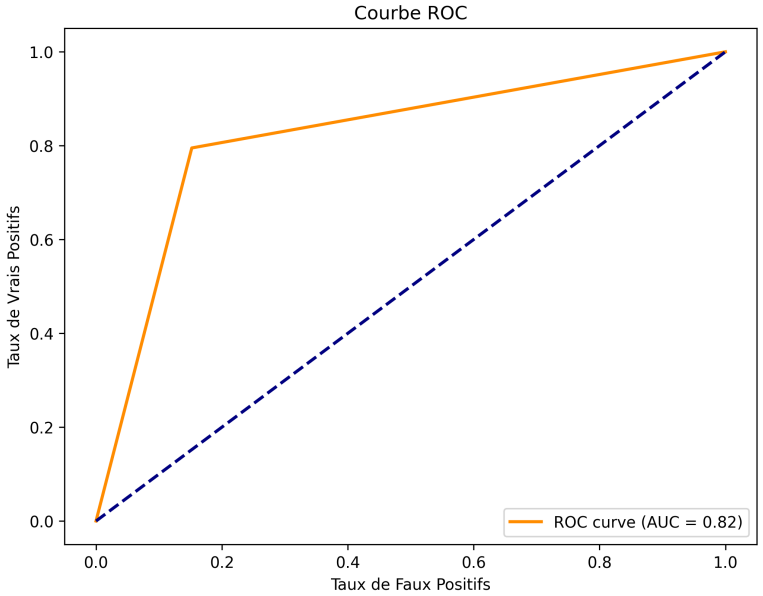

FIGURE 13 – Courbe ROC Decision Tree

4.3 KNN

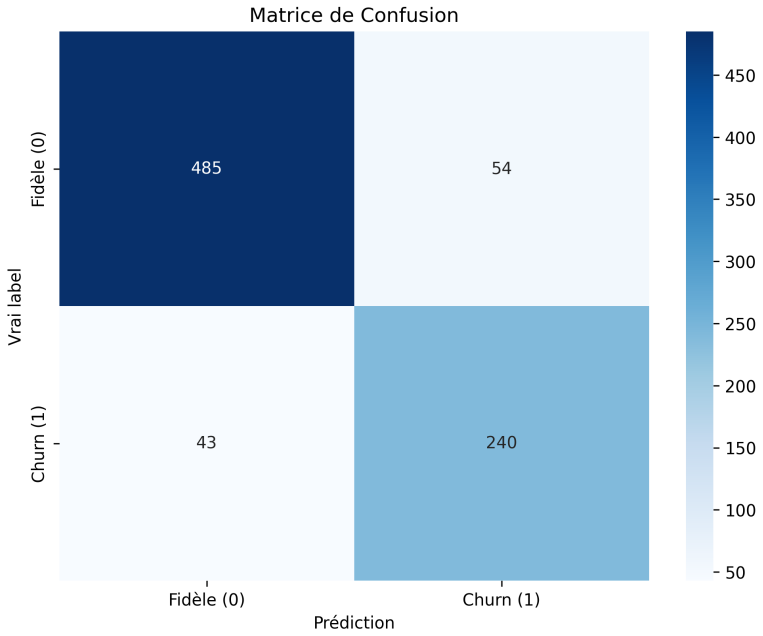

FIGURE 14 – Matrice de confusion KNN

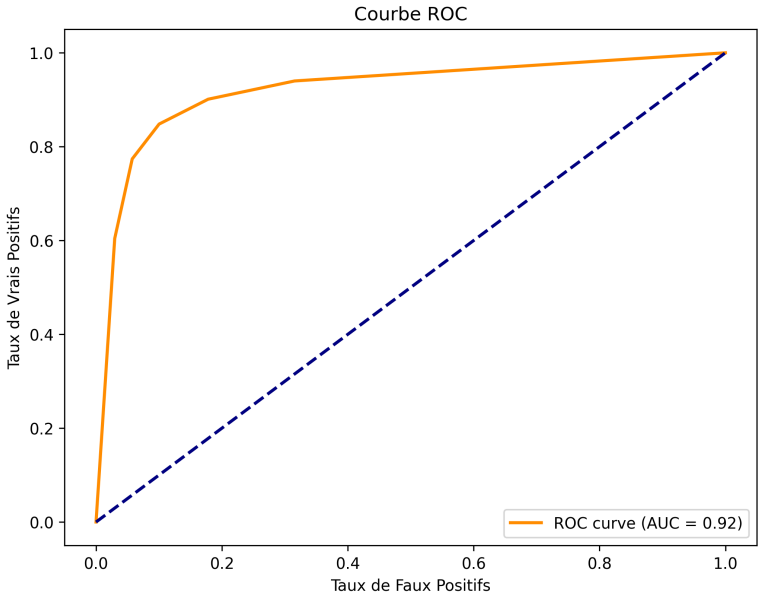

FIGURE 15 – Courbe ROC KNN

4.4 Random Forest

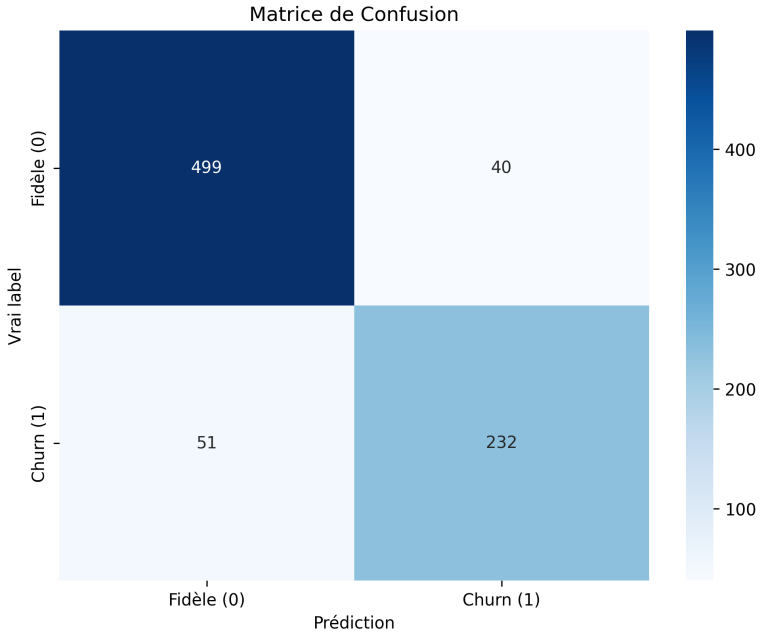

FIGURE 16 – Matrice de confusion Random Forest

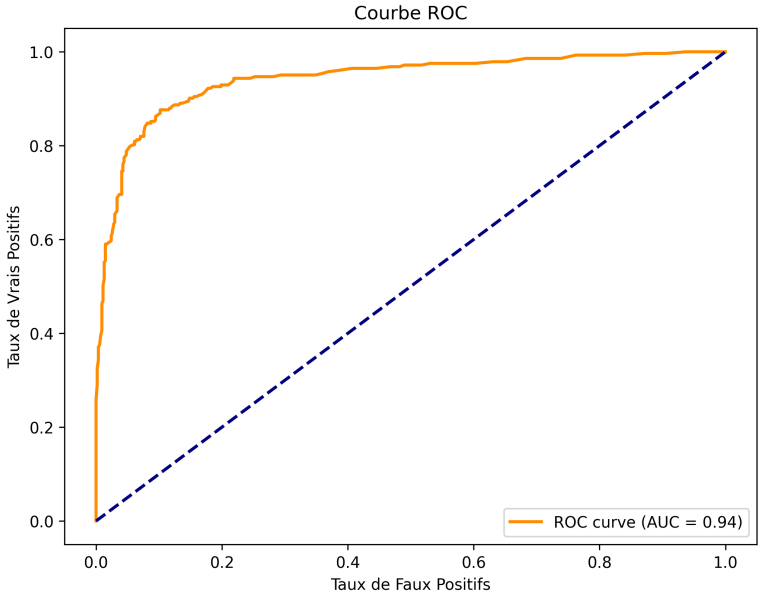

FIGURE 17 – Courbe ROC Random Forest

4.5 XGBoost (Meilleur Modèle)

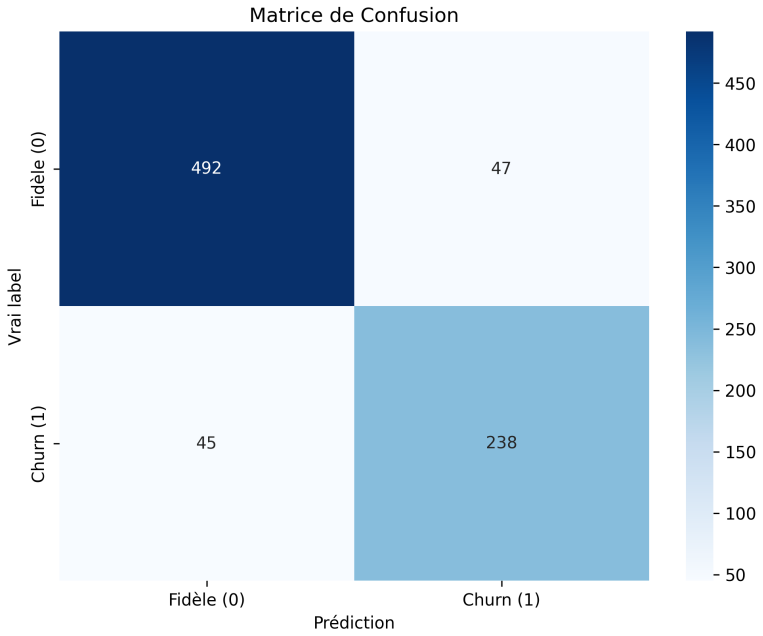

FIGURE 18 – Matrice de confusion XGBoost

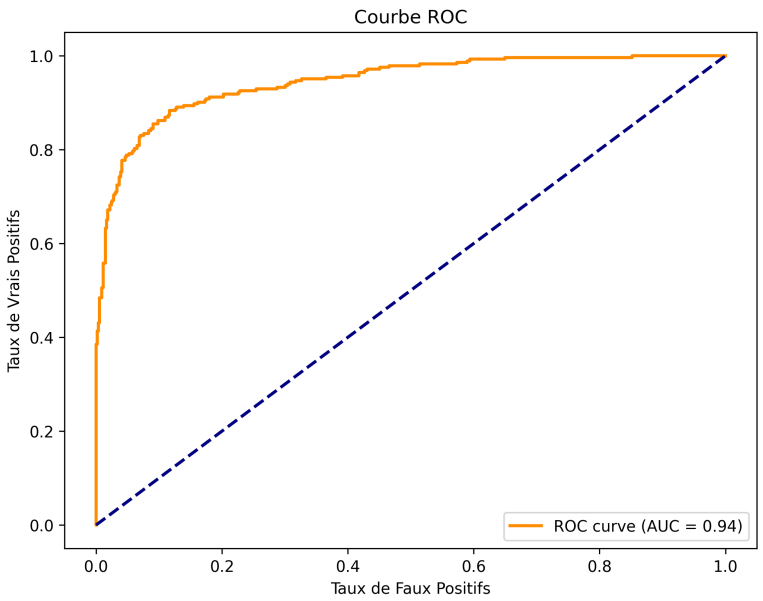

FIGURE 19 – Courbe ROC XGBoost

5 Modélisation Régression

Modèle sur données brutes (data/regression_specific/*.csv).
Entraîné dans notebooks/05_trainREG.ipynb, sauvé comme regression_model_raw.pkl.

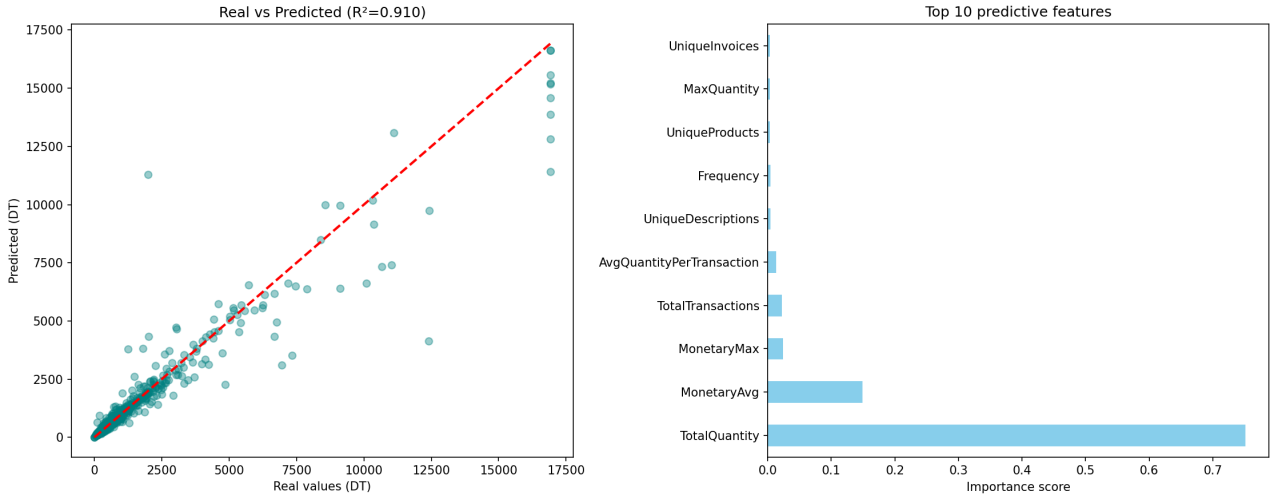

FIGURE 20 – Rapport final régression sur données brutes

Métriques excellentes sur test set.

...

	Metric	Value
0	R^2 (log scale)	0.9625
1	R^2 (real scale)	0.9099
2	CV R^2 mean (5-fold)	0.9651
3	RMSE (DT)	799.6425
4	MAE (DT)	265.0135

FIGURE 21 – Visualisation detaillee des metriques de regression.

Insights Régression

Prédictions précises des valeurs cibles, RMSE faible.

6 Clustering et Réduction de Dimension

Cette partie complète les approches supervisées en apportant une lecture plus exploratoire du portefeuille client. L'objectif n'est pas de prédire une cible, mais d'identifier des groupes homogènes de clients à partir de leurs comportements d'achat, de leur niveau d'engagement et de leur valeur potentielle. Dans le projet global, cette étape permet d'alimenter des actions marketing différenciées, par exemple en distinguant les clients à forte valeur, les profils fragiles proches du churn et les utilisateurs peu engagés.

Le pipeline de segmentation repose sur deux briques complémentaires : la réduction de dimension par ACP pour résumer l'information dans un espace plus lisible, puis le clustering par KMeans pour construire des groupes interprétables. Les artefacts sauvegardés permettent de réutiliser cette chaîne dans l'application et de garantir la cohérence entre les données d'entraînement et les nouvelles observations.

6.1 PCA

Le modèle `pca_model.pkl` est utilisé pour projeter les données clients dans un espace de dimension réduite, généralement à 2 ou 3 composantes principales. Cette étape facilite à la fois la visualisation et la segmentation : elle réduit le bruit, limite la redondance entre variables et permet de représenter plus clairement la structure globale des profils clients.

Dans une logique métier, l'ACP aide à répondre à deux questions essentielles : quelles combinaisons de variables expliquent le plus de variabilité entre les clients, et dans quelle mesure les individus se répartissent naturellement dans l'espace latent obtenu. Les visualisations PCA servent donc de support d'interprétation avant même l'application de l'algorithme de clustering.

6.2 KMeans

Le modèle `kmeans_model.pkl` est ensuite appliqué sur les données transformées afin de construire des segments opérationnels. Le nombre de clusters optimal est recherché dans une plage de `k=3` à `k=5`, ce qui constitue un bon compromis entre lisibilité business et finesse de segmentation. Les groupes identifiés dans ce projet peuvent être interprétés comme des segments du type *High-value*, *At-risk* et *Low-engagement*.

Cette segmentation est particulièrement utile pour relier les résultats techniques à des actions concrètes. Un cluster *High-value* peut être ciblé par des campagnes premium ou des offres de fidélisation. Un cluster *At-risk* peut être surveillé pour anticiper le churn et déclencher des actions de rétention. Enfin, un cluster *Low-engagement* peut révéler un besoin de réactivation, de personnalisation de l'expérience ou d'ajustement des messages marketing.

Captures recommandées à ajouter

Pour enrichir encore cette section dans une prochaine version du rapport, il serait très pertinent d'ajouter : la courbe de la méthode du coude pour justifier le choix de `k`, un nuage de points PCA coloré par cluster, un tableau de profils moyens par segment (revenu, fréquence d'achat, dépense totale, churn moyen) et une capture du code ou du notebook montrant l'enchaînement `scaling` → `PCA` → `KMeans`.

7 Application Flask

L'application a été développée comme une couche de démonstration opérationnelle du projet. Déployée via `app/app.py`, elle permet de passer d'un travail de notebook à une interface exploitable par un utilisateur non technique. Elle centralise le chargement des données, le prétraitement, l'inférence des modèles et la restitution visuelle des résultats dans un même environnement.

7.1 Pipeline applicatif

Le pipeline suivi dans l'application reprend la logique générale du projet de machine learning. L'utilisateur commence par charger un jeu de données, qui est ensuite contrôlé et préparé selon les transformations attendues par les modèles sauvegardés. Après cette phase de prétraitement, l'application permet d'exécuter plusieurs briques : prédiction du churn pour la classification, estimation d'une valeur continue pour la régression et projection/segmentation pour le clustering. Les sorties sont ensuite affichées sous forme de tableaux, d'indicateurs synthétiques et de visualisations interactives afin de faciliter l'interprétation métier.

Cette architecture présente un intérêt important : elle garantit la continuité entre l'entraînement et l'usage. Les mêmes artefacts sauvegardés lors de la phase de modélisation sont réutilisés dans l'interface, ce qui limite les écarts entre expérimentation et démonstration. L'application sert donc à la fois de vitrine fonctionnelle du projet et de support de validation des résultats obtenus dans les notebooks.

7.2 Fonctionnalités principales

- Import des données à analyser depuis l'interface.
- Prétraitement cohérent avec les pipelines utilisés à l'entraînement.
- Prédictions de classification pour identifier les clients à risque de churn.
- Prédictions de régression pour estimer une variable continue liée au comportement ou à la valeur client.
- Visualisations interactives pour explorer les sorties du modèle et la segmentation.
- Restitution synthétique des résultats pour un usage plus orienté décision.

7.3 Captures d'écran de l'application

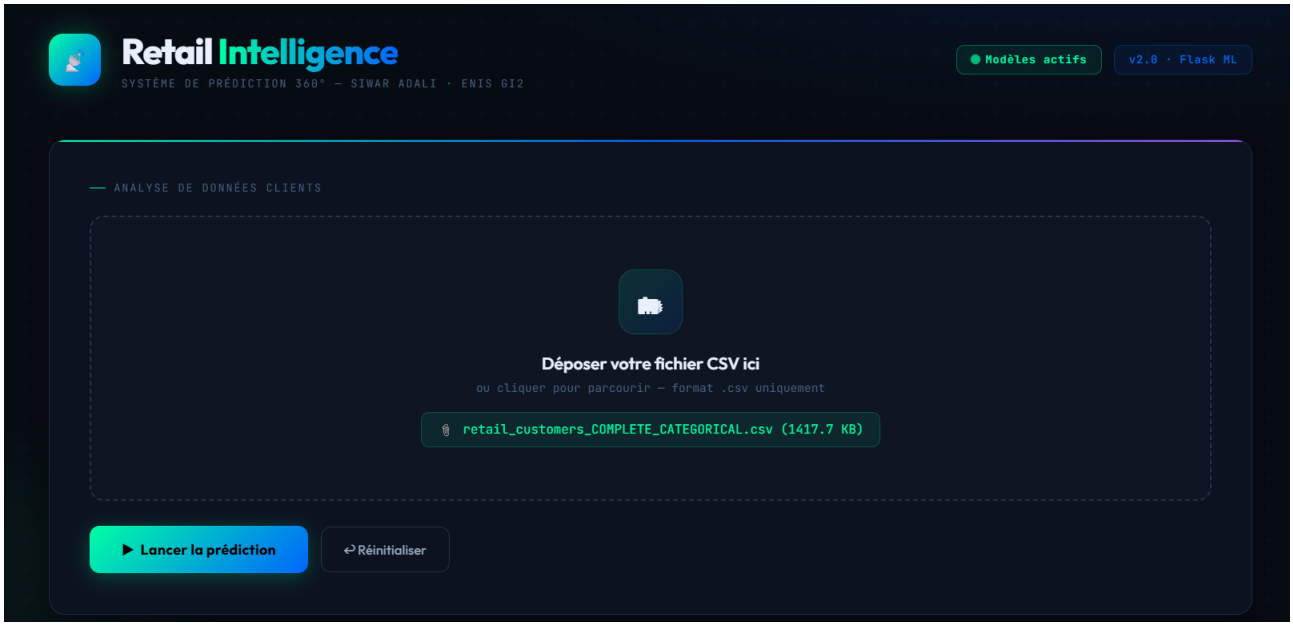

FIGURE 22 – Page d'accueil de l'application. Cette interface introduit les différents modules disponibles et constitue le point d'entrée de l'utilisateur dans le workflow de démonstration.

FIGURE 23 – Étape d'upload et de preprocessing. Elle montre comment les données brutes sont chargées puis préparées avant d'être transmises aux modèles entraînés.

FIGURE 24 – Écran de prédiction du churn. L'application y applique le modèle de classification afin d'identifier rapidement les profils clients les plus susceptibles de se désengager.

FIGURE 25 – Restitution des résultats de classification. Cette vue permet de commenter les sorties du modèle à travers des indicateurs et des visualisations plus lisibles pour l'utilisateur final.

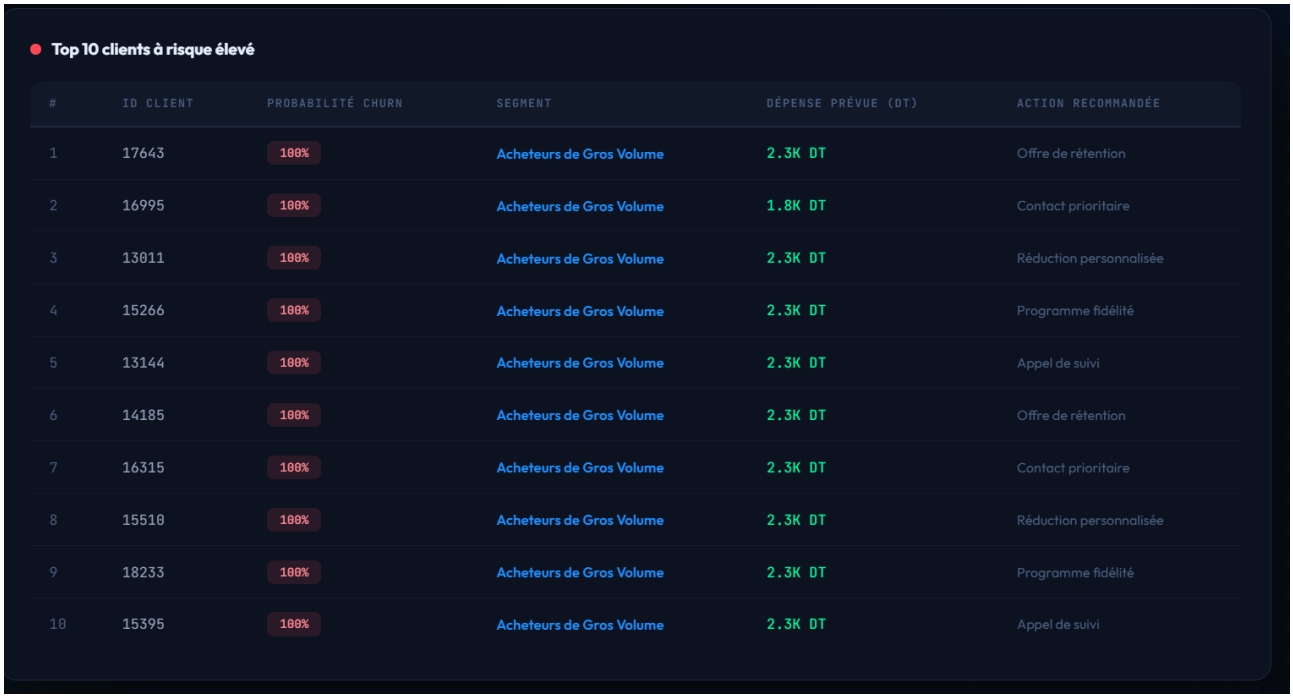

Top 10 clients à risque élevé

#	ID CLIENT	PROBABILITÉ CHURN	SEGMENT	DÉPENSE PRÉVUE (DT)	ACTION RECOMMANDÉE
1	17643	100%	Acheteurs de Gros Volume	2.3K DT	Offre de rétention
2	16995	100%	Acheteurs de Gros Volume	1.8K DT	Contact prioritaire
3	13011	100%	Acheteurs de Gros Volume	2.3K DT	Réduction personnalisée
4	15266	100%	Acheteurs de Gros Volume	2.3K DT	Programme fidélité
5	13144	100%	Acheteurs de Gros Volume	2.3K DT	Appel de suivi
6	14185	100%	Acheteurs de Gros Volume	2.3K DT	Offre de rétention
7	16315	100%	Acheteurs de Gros Volume	2.3K DT	Contact prioritaire
8	15510	100%	Acheteurs de Gros Volume	2.3K DT	Réduction personnalisée
9	18233	100%	Acheteurs de Gros Volume	2.3K DT	Programme fidélité
10	15395	100%	Acheteurs de Gros Volume	2.3K DT	Appel de suivi

FIGURE 26 – Module de prédiction régression. Il illustre l'estimation d'une cible continue et montre comment les résultats peuvent être interprétés dans une logique de valeur client ou de comportement d'achat.

FIGURE 27 – Visualisation du clustering. Cette interface aide à explorer la répartition des clients dans l'espace réduit et à mieux comprendre la logique des segments obtenus.

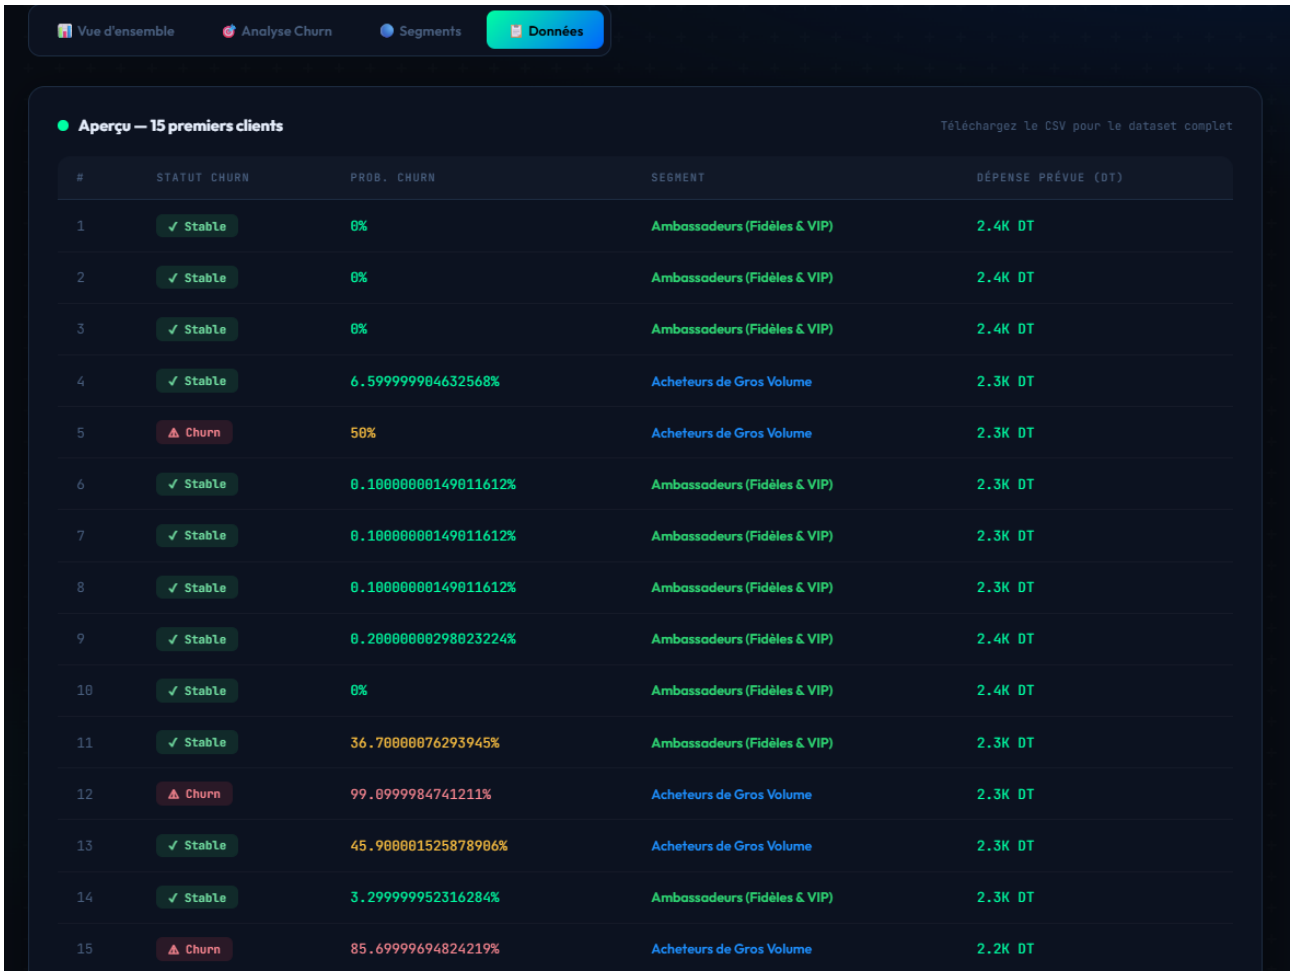

#	STATUT CHURN	PROB. CHURN	SEGMENT	DÉPENSE PRÉVUE (DT)
1	✓ Stable	0%	Ambassadeurs (Fidèles & VIP)	2.4K DT
2	✓ Stable	0%	Ambassadeurs (Fidèles & VIP)	2.4K DT
3	✓ Stable	0%	Ambassadeurs (Fidèles & VIP)	2.4K DT
4	✓ Stable	6.599999904632568%	Acheteurs de Gros Volume	2.3K DT
5	⚠ Churn	50%	Acheteurs de Gros Volume	2.3K DT
6	✓ Stable	0.10000000149011612%	Ambassadeurs (Fidèles & VIP)	2.3K DT
7	✓ Stable	0.10000000149011612%	Ambassadeurs (Fidèles & VIP)	2.3K DT
8	✓ Stable	0.10000000149011612%	Ambassadeurs (Fidèles & VIP)	2.3K DT
9	✓ Stable	0.20000000298023224%	Ambassadeurs (Fidèles & VIP)	2.4K DT
10	✓ Stable	0%	Ambassadeurs (Fidèles & VIP)	2.4K DT
11	✓ Stable	36.70000076293945%	Ambassadeurs (Fidèles & VIP)	2.3K DT
12	⚠ Churn	99.0999984741211%	Acheteurs de Gros Volume	2.3K DT
13	✓ Stable	45.900001525878906%	Acheteurs de Gros Volume	2.3K DT
14	✓ Stable	3.299999952316284%	Ambassadeurs (Fidèles & VIP)	2.3K DT
15	⚠ Churn	85.69999694824219%	Acheteurs de Gros Volume	2.2K DT

FIGURE 28 – Dashboard d'insights. Il regroupe une vue plus synthétique des résultats pour soutenir l'analyse métier, la communication des conclusions et la prise de décision.

8 Conclusion et Perspectives

8.1 Résultats Clés

- XGBoost : 91% accuracy churn - Bonne performance régression - Clustering efficace - App déployée

8.2 Insights Business

— Mettre en place des actions de rétention ciblées sur les clients identifiés comme *at-risk*, afin de réduire le churn grâce à des campagnes personnalisées, des offres incitatives ou un suivi plus proactif de leur engagement.

— Développer des stratégies d'upselling et de fidélisation spécifiques pour les segments *high-value*, qui représentent les profils les plus rentables et les plus stratégiques pour la croissance de l'entreprise.

— Exploiter les résultats du modèle de régression pour mieux ajuster les décisions liées au pricing, à la valeur client attendue et à la priorisation des offres commerciales selon le potentiel estimé de chaque profil.

8.3 Perspectives

— Explorer des approches de *deep learning*, notamment des architectures de type LSTM ou d'autres modèles séquentiels, afin de mieux exploiter une éventuelle dimension temporelle dans les comportements d'achat et d'améliorer l'anticipation du churn.

— Enrichir le travail de *feature engineering* avec des variables plus avancées, par exemple des indicateurs RFM (*Recency, Frequency, Monetary*), des ratios comportementaux ou des scores composites permettant de capturer plus finement la valeur et l'engagement client.

— Étendre le projet vers un déploiement cloud sur des plateformes comme Heroku, AWS ou des services équivalents, afin de rendre l'application plus accessible, plus robuste et plus proche d'un cadre réel d'exploitation en production.

— Mettre en place des démarches d'A/B testing autour des prédictions et des recommandations générées, dans le but d'évaluer concrètement l'impact business des modèles sur la rétention, la conversion et la performance des campagnes marketing.